协程简史，一文讲清楚协程的起源、发展和实现

陈蒙 郭霖 2022-10-08 08:00 发表于江苏

/ 今日科技快讯 /

北京时间10月5日下午，在瑞典首都斯德哥尔摩，瑞典皇家科学院宣布，将2022年诺贝尔化学奖授予美国化学家卡罗琳·贝尔托西、丹麦化学家摩顿·梅尔达尔和美国化学家卡尔·巴里·夏普莱斯，以表彰他们在点击化学和生物正交化学研究方面的贡献。其中，卡尔·巴里·夏普利斯第二次获得诺贝尔化学奖。

/ 作者简介 /

大家好，国庆假期结束，我们又如期见面了。记得从今天起要连上7天班哦。

本篇文章来自陈蒙的投稿，文章主要分享了协程的起源，发展和常见实现，相信会对大家有所帮助！同时也感谢作者贡献的精彩文章。

陈蒙的博客地址：

> https://chenmeng.blog.csdn.net/?type=blog

/ 前言 /

如果说大前端开发有什么金规铁律的话，那「不要阻塞主线程」肯定算一个。特别是面对网络请求等耗时任务时，异步编程是避免主线程卡死的常见解决方案。协程是诸多异步编程范式中的一种。相较于多线程、回调、Promise、响应式编程等其他异步编程范式，协程具有轻量级、代码可读性好等优点。当前主流编程语言要么已经支持了协程，要么正在支持的路上。本文将从起源、发展历史、常见语言实现等角度进行介绍，力求为大家展示协程的全貌。

/ 概念释义 /

协程定义

维基百科对协程定义的英文原文：

Coroutines are computer program components that generalize subroutines for non-preemptive multitasking, by allowing execution to be suspended and resumed.

是不是觉得晦涩难懂？每个单词都认识，但是连在一起就不知所云了。我们先往下看，后面再逐词解释。

除了维基百科，我们也许还见过别的定义，这些定义多是从某个角度描述协程特性的。

比如侧重其轻量级特性的：

Coroutines are very light-weight threads.

或者

Coroutines are like very light-weight threads.

虽只有一字之差，却是天壤之别。

侧重其暂停/恢复特性的：

A coroutine is an instance of suspendable computation.

侧重其表现形式的：

A variant of functions that enables concurrency via cooperative multitasking.

CoRoutine，其中 Co 是 Cooperative，意为平等、协作，指多段程序之间相互转移控制权；Routine 一词在高级语言中对应函数/方法等概念，即 Routine 与 Program、Subprogram、Function、Method、Subroutine、Procedure、Callable Unit 等词同义。故协程可以简称为协作的程序。

普通程序是主程序（Main）-子程序（Subroutine）的关系，一旦主程序调用（call）子程序，那么子程序独占控制权直到执行完成（return），是一种 call-return 的结构。通常，子程序一旦返回主程序，子程序的上下文就消失了，当主程序再次调用子程序时子程序需要重头开始执行一遍。

而协程不是 call-return 的结构，而是 suspend-resume 的结构，即在其中一段程序尚未执行完成时就向另一段程序移交控制权，而且前者会保存自己的上下文，以便稍后恢复现场继续执行。

从协程的调用行为上看，主程序既可以调用子程序，子程序也可以调用主程序，是一个双向的调用关系，并不是普通程序那种单向的调用-被调用的关系。

所以协程可以看做是对普通程序（Subroutine）的泛化（generalize），而普通程序是协程的一种特例（0个暂停点、单向的调用关系）。就像是打排球一样，如果把双方看成是有调用关系的程序，双方你来我往，地位是对等的，所以是一种 Co 的关系。引用发明协程这一概念的作者的原话，协程是：“as subroutines who act as the master program”。

普通程序和协程的对比见下图：

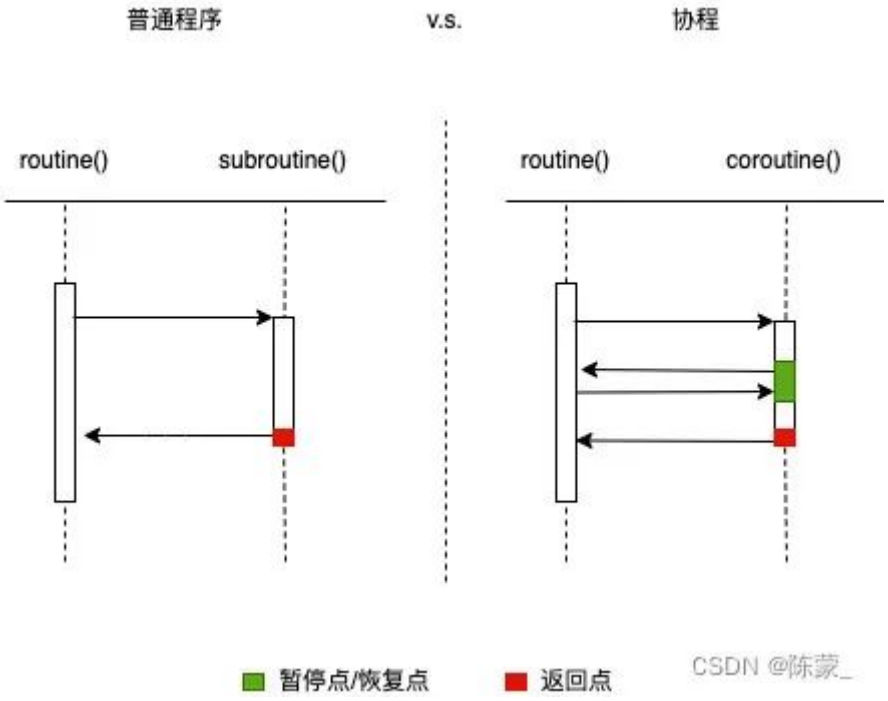

其实协程还代表了一种非抢占式的多任务并发的调度思想：协作式调度。每个任务执行完毕之后才将 CPU 的使用权转移给另一个任务，没有优先级和抢占，十分和谐。

我们可以参考做核酸对比下协作式和抢占式调度。我们把大白当做 CPU，每个居民当做一个任务。协作式调度就是一旦有居民坐在椅子上了，后面的人就必须等他主动让出椅子才能做核酸，否则就要一直等。而抢占式就有了优先级的概念，就是允许更高优先级的居民先做，即使前面的人已经坐在椅子上张开嘴巴了，此时后面来个人说“我家小朋友要上网课，能让我们先做吗？”，这时前面的人可以把位置让给这个更高优先级的人。

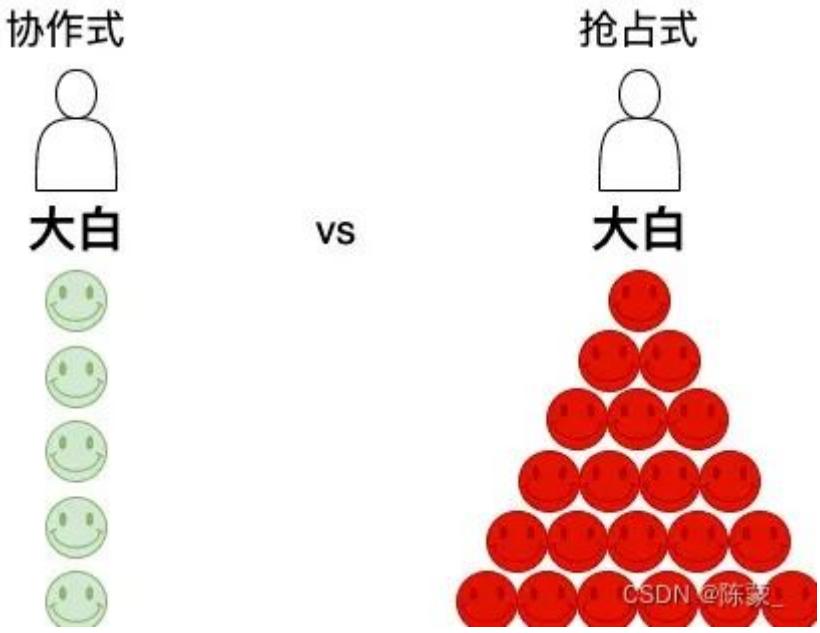

此时我们再回头看维基百科的定义，可能就清晰多了：

Coroutines are computer program components that generalize subroutines for non-preemptive multitasking, by allowing execution to be suspended and resumed.

广义上而言，协程是一个概念，就像肉夹馍一样，每个地方的具体做法都不完全相同。狭义上来说，协程是一段程序。介于二者之间，还有编程语言关键字、编译器/执行引擎支持、运行时系统等辅助系统，这些统称为组件（Component）。什么样的程序呢？是对普通程序的泛化的程序。能够支持协作式多任务调度，而且是通过代码执行的暂停和恢复的方式实现的。

从这个定义里面，我们可以得出协程最明显的特征：（1）转移控制权时保存上下文（2）可以被暂定，而后从暂停点开始继续执行。

“Talk is cheap，show me the code”。假如我们发明了一门新的编程语言叫BePositiveBePatient（在做核酸的日子里，我们更需要保持积极的心态和耐心，大家千万不要翻译成“成为阳性、成为病人”），简称BPBP，它有两个关键字 yield/resume。我们用BPBP语言写出如下打印斐波那契数列的代码：

```
function main() {
   var gen = fib()

   var a = resume(gen) // 1
   var b = resume(gen) // 2
   var c = resume(gen) // 3
   var d = resume(gen) // 5
}

// 斐波那契数列生成器，1，2，3，5
function fib() -> Number {
   yield 1
   yield 2
   yield 3
   return 5
}
```

执行到 resume 时就会进入 fib()，执行到 yield 时就会返回到 main()，yield 的作用跟 return 类似，但不会终止当前方法体的执行，执行过程见下图：

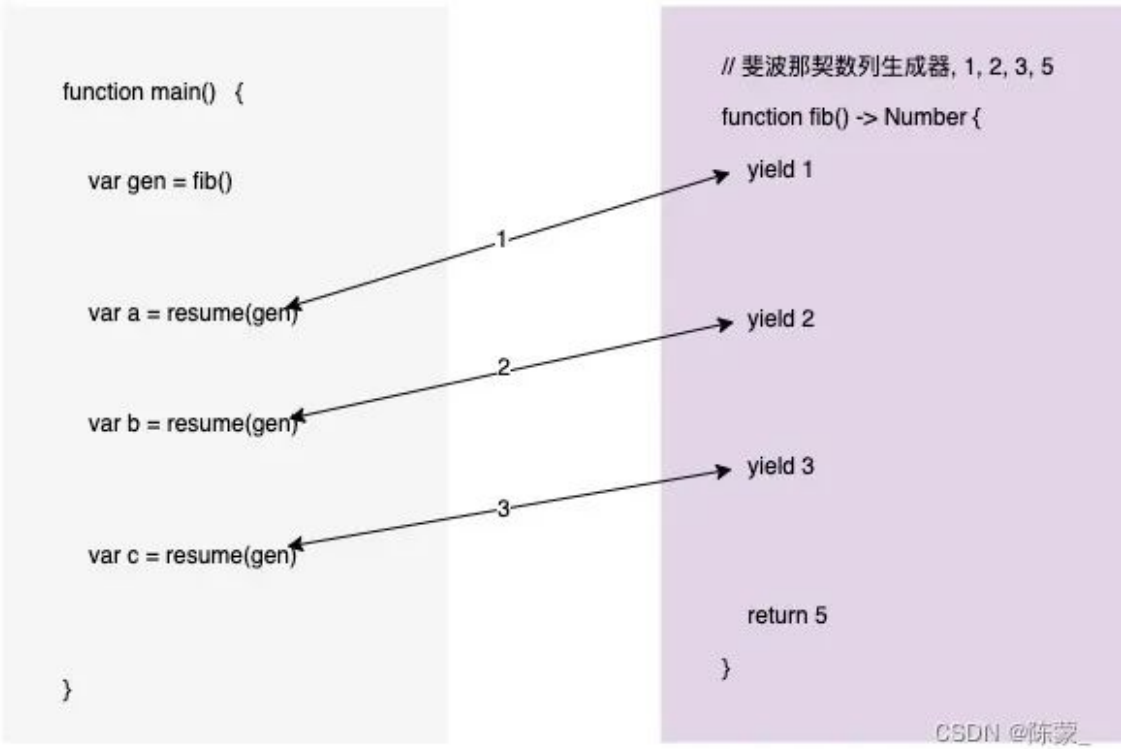

与线程的关系

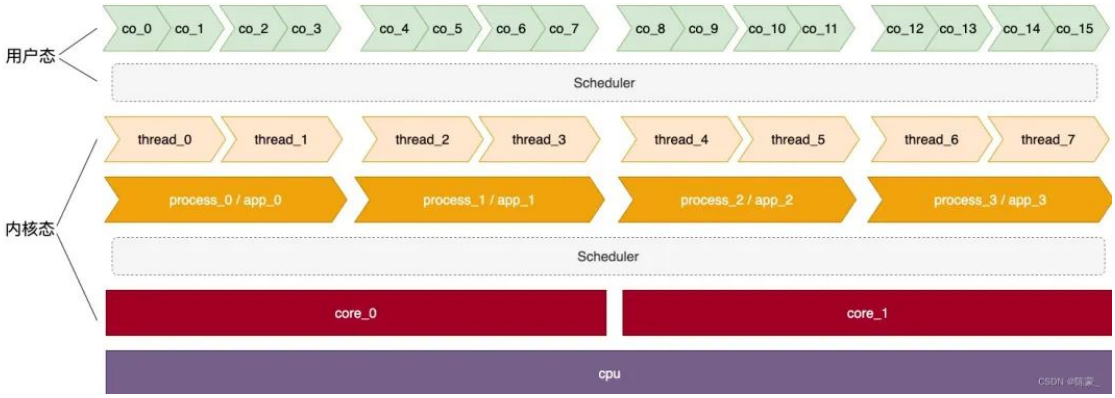

协程是 1963 年正式提出的，而在之后的 1966 年，才有了线程（thread）的概念。

同一时刻，同一个 CPU 的某个核心（Core）上，只有一个进程的一个线程的一个协程（如果有）在运行。

一个进程包含至少一个线程（主线程），一个线程里面有0个或多个协程，一个协程是以线程为宿主进行的计算活动。协程一旦确定宿主线程，一般不会再更改。

进程是资源分配的基本单位，线程（内核态）是 CPU 调度的基本单位，协程对于 OS 来说是透明的。协程被认为是用户态的线程，协程的调度由用户完成。
进程向自己所属线程开放内存空间，线程有自己的堆栈、程序计数器、寄存器数据。

一个线程消耗的内存一般在 MB 级别，而协程占用内存一般在几十到几百字节，Goroutine 经过层层优化后占用 2KB。为了解决线程之间竞争的问题，每个线程还会在自己的内存空间中额外申请64MB内存来作为堆内存池，使得操作系统的内存无法支撑几万个线程的并发，但是这对协程却不是个问题。

线程上下文切换的成本在几十纳秒到几微秒间，当线程繁忙且数量众多时，这些切换会消耗绝大部分的CPU运算能力。

比较对象	地址空间	调度器	内存占用	切换内容	切换的内容保存于	切换过程	切换效率
进程	独有	OS 内核	MB	页全局目录，内核栈，寄存器	内核栈	用户态-内核态-用户态	低
线程	共享	OS 内核	MB	内核栈，寄存器	内核栈	用户态-内核态-用户态	中
协程	共享	用户	<= 2KB	寄存器	用户栈/堆	用户态	高

协程简史

1958 年，Melvin Conway 创造了协程（Coroutine）一词。

1963 年，协程这一概念正式发布于论文 Design of a Separable Transition-Diagram Compiler 中。

在这篇论文中，Conway 提出将 COBOL 编译过程中的词法分析和语法分析结合起来完成，而不是将二者看成是完全独立的步骤。词法分析和语法分析分别有自己的控制流，在 Conway 的方法里，这两个控制流可以保存自己运行的上下文并移交执行权给对方，并在合适的时候恢复自己的上下文并继续执行。这种概念就叫做协程。

论文原图

基本思想

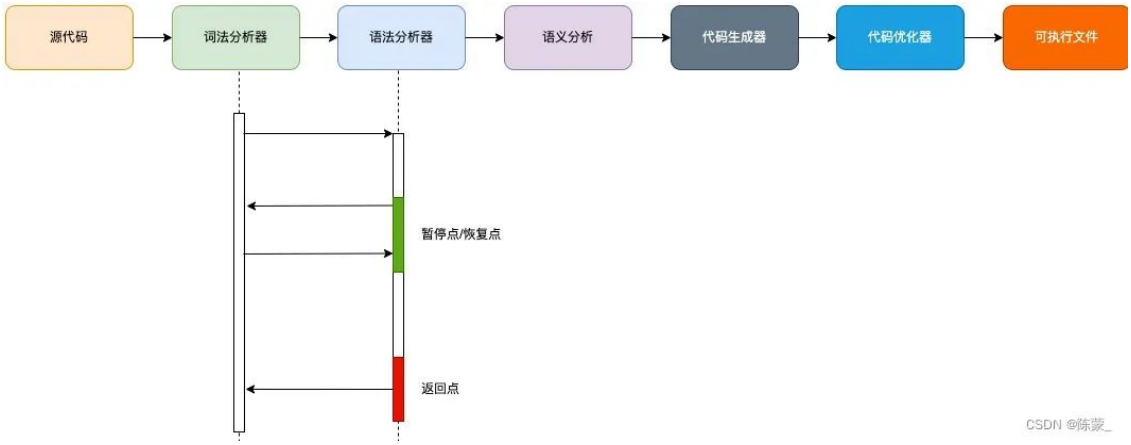

- 1966 年，线程（thread）的概念被提出。
- 1968 年，Dijkstra 发表论文《GOTO 语句是有害的》，结构化编程的理念深入人心，自顶向下的程序设计思想成为主流，协程“跳来跳去”的执行行为类似 goto 语句，违背自顶向下的设计思想。
- 1979 年，Marlin 提交博士论文 Coroutines：A Programming Methodology, A Language Design, and An Implementation，是协程理论的集大成之作。
- 1980 年及之后的 20 余年，多线程成为并发编程的代名词，抢占式击败协作式成为主流的调度方式，协程逐渐淡出主流编程语言舞台。
- 2003 年，Lua v5.0 版本开始支持协程。
- 2005 年，Python 开始支持生成器和 yield/send 关键字，之后数年一直在演化。
- 2009 年，Go 语言问世，以 Goroutine 的方式支持并发编程，一代传奇拉开序幕。
- 2012 年，C# 开始支持 async 函数和 await 表达式，标志着协程王者归来。

- 2015 年，Python 支持 async/await 语法。
- 2017 年，async/await 纳入 ES2017 标准。
- 2017 年，Kotlin 另辟蹊径，以 suspend 关键字的形式实现了协程。
- 2019 年，Dart 支持 Future、async/await 语法。
- 2020 年，C++ 20 支持 co_async/co_await。
- 2022 年 3 月，JDK 19 预览版（Early-Access）中引入了一种新的并发编程模型（织布机计划）——虚拟线程，非最终版，可能随时被删除。

如果我们将上述 60 年的历史事件绘成图，一个圆代表一个事件，用面积大小代表其影响力大小，则有：

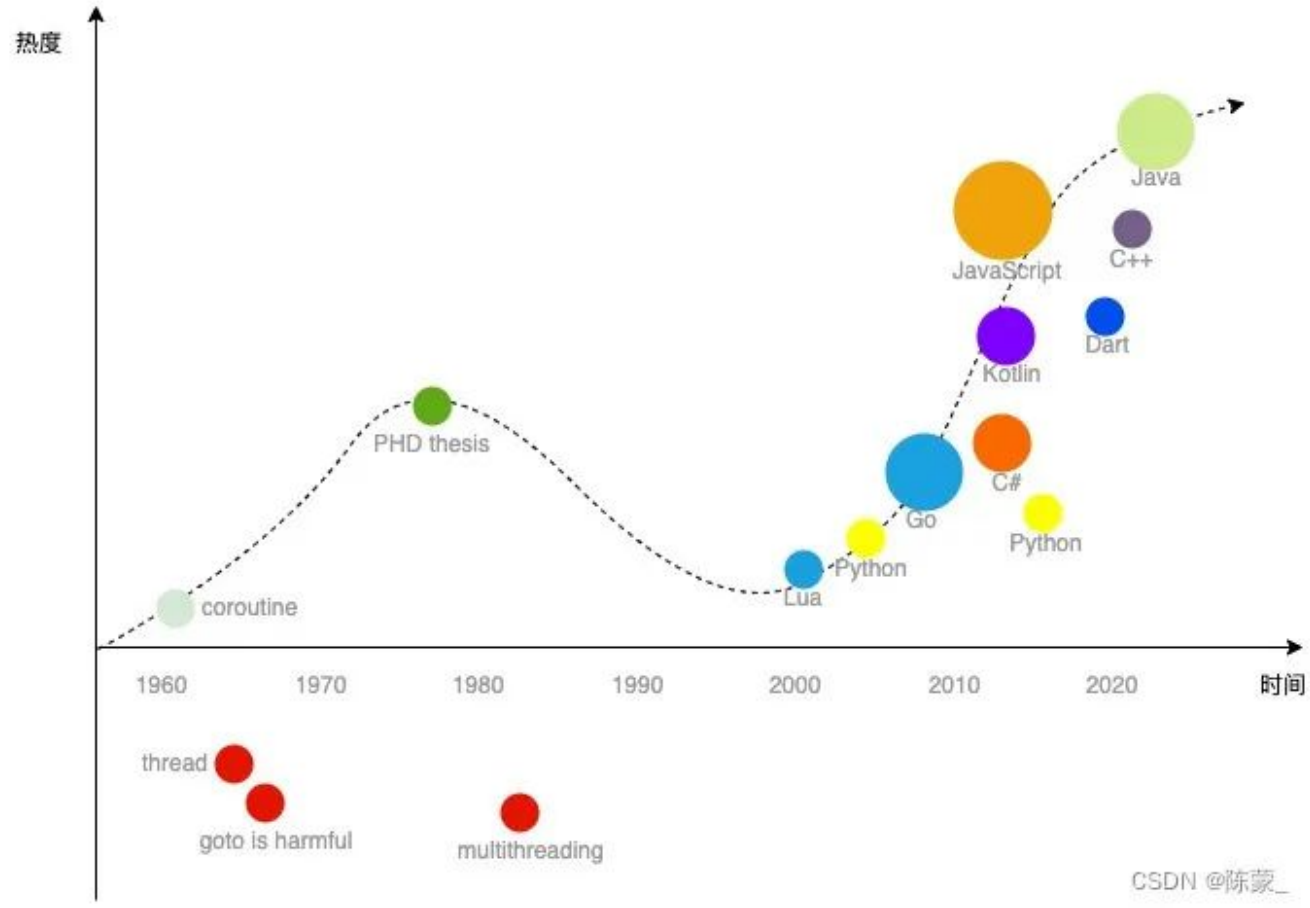

/ 种类划分 /

以下分类方式是参考论文 Revisiting Coroutines 得出。

按调用栈分类

实现协程的关键是暂停/恢复代码的执行，实现方法有两种：栈，状态机&闭包。

首先，抛开具体语言实现，我们来回顾下一个线程中方法调用的一般流程。方法的执行过程是借助方法调用栈实现的，栈内每个元素称为栈帧（Frame Stack）。还有一些和栈相关的寄存器，包括栈指针 ESP，指向栈的顶部，其存贮的地址随着栈帧的入栈和出栈而不断变化，总是指向栈的最后一个元素；基指针 EBP，指向当前运行的方法的一个固定位置，起到锚点的作用，为访问函数参数和局部变量提供参考点；EIP/PC 寄存器，指向 CPU 即将执行的下一条指令。调用一个子方法时该方法会以栈帧的形式入栈，子方法执行完成之后会出栈，结合寄存器内容的变化，CPU 可以完成方法调用过程。

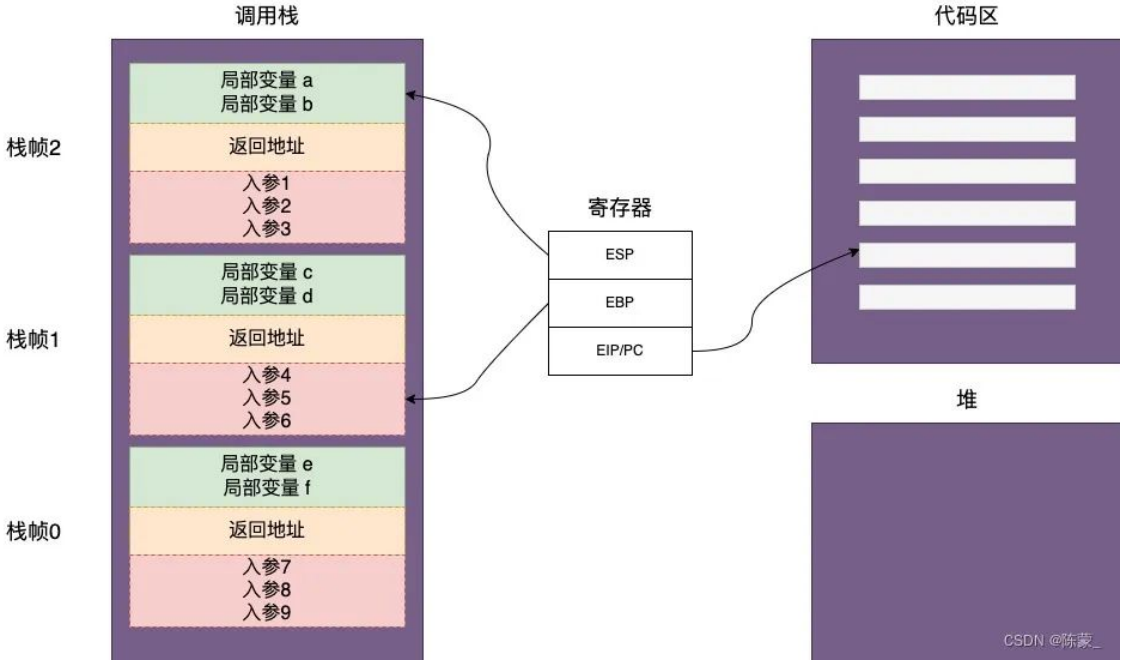

假如我们有如下的代码：

```
function main() {
   const a = 1
   const b = 2
   const c = add(a, b)
   print(c)
   return
}

function add(a, b) {
   const d = a + b
   return d
}
```

则上述代码在执行过程中的调用栈变化如下图：

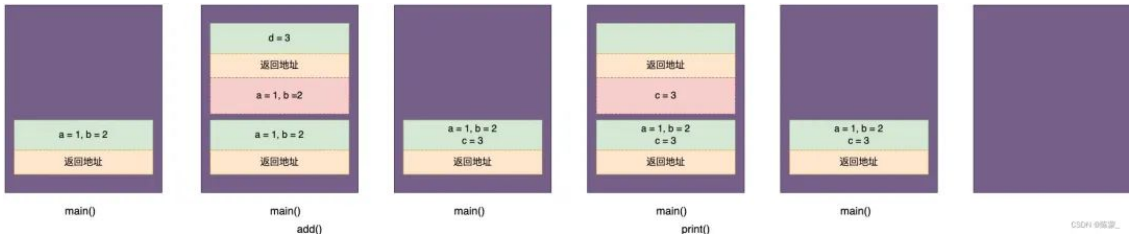

参考线程实现暂停/恢复的方式，我们可以把协程暂停点涉及的调用栈、 EIP（程序计数器 PC）、EBP、ESP 等寄存器数据保存一份“快照”，当协程需要从暂停点恢复执行时，只需恢复这个快照即可。利用这种方式实现的协程被称为有栈协程（Stackful Coroutine），代表作 Go 和 Lua。有栈协程有时被称为 Fibers 或者用户态线程。

我们回顾一下设计模式中的迭代器模式。我们在开发过程中会用到各种数据结构，包括数组、列表、树等。每种数据结构有不同的遍历方式，有的用下标，有的用引用、指针。而实际我们只关心数据结构中是否还有元素以及获取下一个元素，并不关心其内部构造。根据面向对象编程中封装的原则，我们可以各种数据结构或集合实现一个统一的接口 Iterator，对外暴露 hasNext() 和 next() 方法，这样我们每次调用 next() 方法时就可以获取上次调用之后应该得到的元素，就跟迭代器“暂停”后又被“恢复”执行了一样。

但是我们知道，迭代器并没使用魔法，甚至也没有借助额外的“栈”去保存状态，迭代器宿主本身是个变量，可以保存状态，再借助适当的代码结构，达到“暂停”和“恢复”的执行效果。这也是实现协程的一种思路，常见手段是利用状态机和闭包，通过状态机和闭包来存储暂停点代码的现场信息。利用这种方式实现的协程称为无栈协程（Stackless Coroutine），代表作是 JavaScript、Kotlin 等，共同点是关键字 async/await。我们会在后续章节中通过 Kotlin 的协程实现来具体说明。

有栈和无栈协程的对比表如下：

对比项	无栈	有栈
特点	可以暂停和恢复执行的方法，暂停点是方法体内的关键字标记	用户态的可协作式调度的线程，可在任何函数位置请求上下文切换
内存占用	~16字节+暂停点涉及的局部变量	goroutine：2KB
切换开销	2条指令	23-69条指令
实现成本	低	高，需要改写全部同步和阻塞 API
构造成本	现场数据位于堆上或以局部变量的形式存在	需要通过系统调用创建协程栈
平台依赖性	不依赖平台，由编译器实现	可能依赖 OS 支持动态扩充栈的能力
开发效率	接近完美	完美
代表语言	JavaScript、Dart、Kotlin 等	Go、Lua

按调度方式分类

协程的暂停和恢复涉及转移控制权，可以分为非对称协程和对称协程。

非对称协程一般有两个转移指令：暂停指令和继续指令。非对称协程暂停之后其控制权必须转移给继续指令所在的协程，二者之间存在一种较弱的调用方和被调用方的关系。非对称协程又被成为半对称协程（semi-symmetric coroutine）或半协程（semi coroutine）。非对称协程常见于生成器或迭代器场景，用于产生数据流。比如我们在之前章节创造的 BPBP 语言就属于非对称协程：

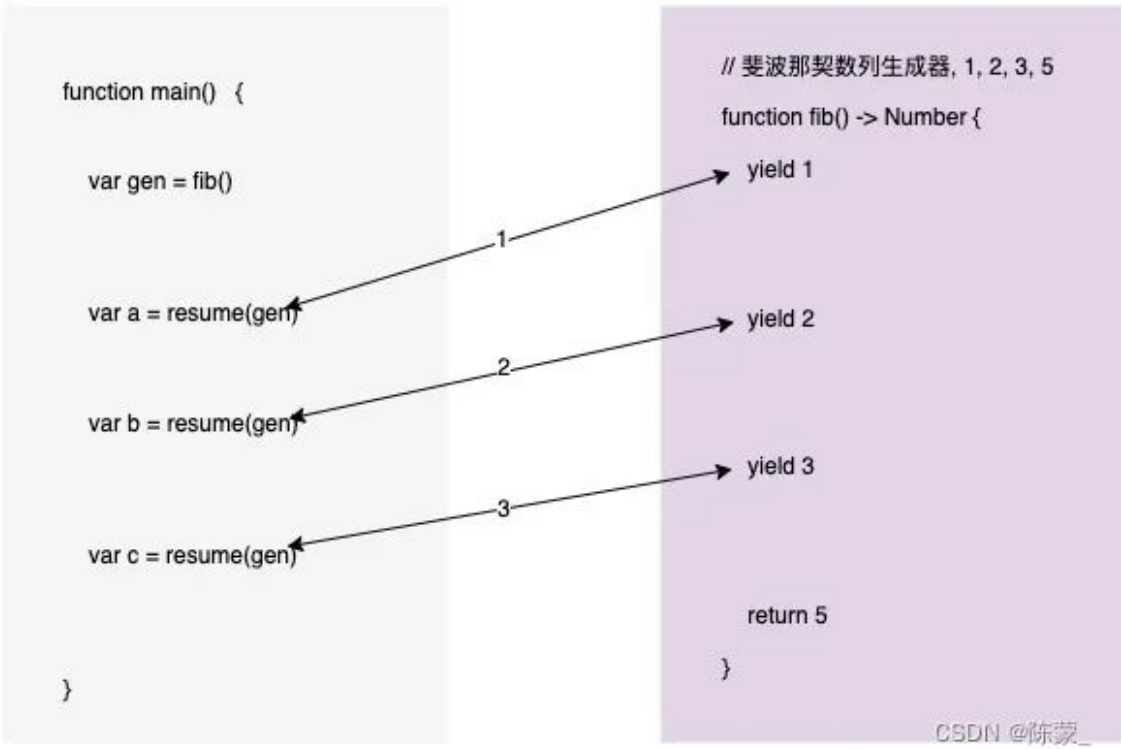

对称协程只有一个转移指令，各个协程之间的地位是“平等”的，控制权可以在多个协程之间转移：

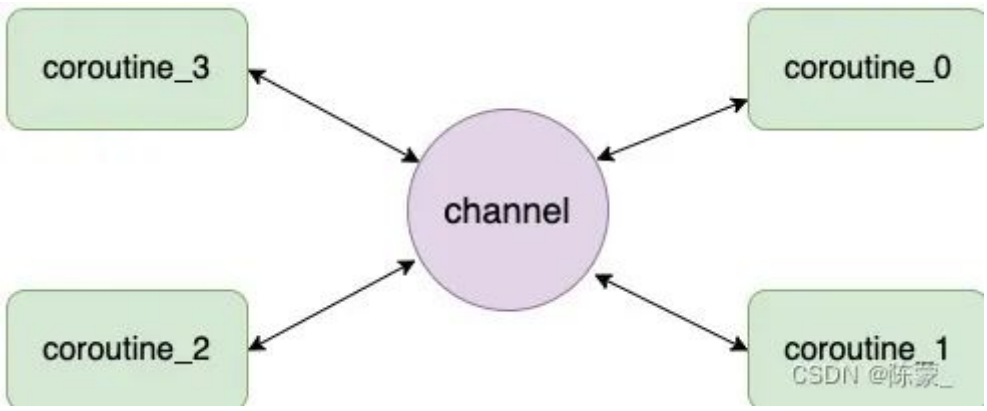

比如 Go 的协程控制权是通过 channel 来完成转移的，channel 内部执行了类似 yiled/resume 原语。

Go语言通过 go 关键字来构建协程。比如下面的程序实现了一个生产者协程（writer）和两个消费者协程（reader），生产者往 channel 里面写入数字，而消费者从 channel 中读取数字。

```
package main

import (
   "fmt"
   "sync"
   "time"
)

var channel = make(chan int)
var readChannel <-chan int = channel
var writeChannel chan<- int = channel
var waitGroup = sync.WaitGroup{}

func main() {
   waitGroup.Add(3)

   go writer()
   go reader1()
   go reader2()

   waitGroup.Wait()
}

// reader1
func reader1() {
   fmt.Println("wait1 for read")
   for i := range readChannel {
      fmt.Println("read1", i)
   }
   fmt.Println("read1 end")
   waitGroup.Done()
}

// reader2
func reader2() {
   fmt.Println("wait2 for read")
   for i := range readChannel {
      fmt.Println("read2", i)
   }
   fmt.Println("read2 end")
```

```
    waitGroup.Done()
}

// writer
func writer() {
    for i := 0; i < 3; i++ {
        fmt.Println("write", i)
        writeChannel <- i
        time.Sleep(time.Second)
    }
    close(writeChannel)
    waitGroup.Done()
}
```

从代码运行结果我们可以看出，三个协程之间的控制权转移是“平等”的，没有严格的“定向”转移关系（可以使用在线编译工具复现）：

```
wait2 for read
wait1 for read
write 0
read2 0
write 1
read1 1
write 2
read2 2
read1 end
read2 end
```

下表是2021 IEEE 编程语言排行榜，我们列举了排名前 20 的语言以及 Objective-C 和 Lua，并标记了每种编程语言是否原生支持协程以及其所属协程种类（以下数据基于 2022.04 月得出）：

排名	语言	协程	有栈/无栈	对称/非对称	关键字	备注
1	Python	是	asyncio是无栈协程	非对称	async/await	v3.5+
2	Java	否	/	/	jdk 19 project loom, quasar	
3	C	否	/	/	/	Coroutines in less than 20 lines of standard C，Coroutines in C
4	C++	是	无栈	非对称	co_async/co_await	C++20
5	JavaScript	是	无栈	非对称	Promise, async/await	ES2017
6	C#	是	无栈	非对称	Task, async/await, actor	v5.0+
7	R	是	无栈	非对称	async(), await(), yiled()	R 3.5.0+, rlang 0.4.12+
8	Go	是	有栈	对称	go/channel	
9	HTML	否	/	/	/	
10	Swift	是	无栈	非对称	Task, async/await, actor	v5.5+
11	Arduino	否	/	/	AceRoutine	
12	Matlab	否	/	/	/	
13	PHP	是	有栈	非对称	v8.1 fibers	
14	Dart	是	无栈	非对称		
15	SQL	否	/	/		
16	Ruby	是	有栈	非对称	fibers	v2.5+
17	Rust	是	无栈/有栈	非对称	tokio, async-std	v1.39+，coroutine
18	Assembly	-	-	-		
19	Kotlin	是	无栈	非对称	suspend, async/await	
20	Julia	是	无栈	对称		
.....	.....	.....	.....			
26	Objective-C	否	/	/		
27	Lua	是	有栈	非对称	coroutine.create，coroutine.resume，coroutine.yield	
.....	.....	.....	.....			

从上面的表格可以看出，主流编程语言都已经支持协程或者正在支持的路上。让人不由的感慨：编程语言也好卷，不支持协程的语言出门都不好意思跟人打招呼（Java：你直接报我身份证吧）。

/ 异步编程 /

异步编程可以看成是并发编程的近义词。需要区分下并行和并发。并行（Parallel）指物理上并行，即至少要有2个CPU或核心，硬件上支持同时至少2个线程同时运行。而并发（Concurrent）则是逻辑意义上的并行，即使硬件上只有1个CPU或1个核心，也可以通过时间分轮转等算法实现多任务调度，给人感官上的“并行”，其实我们知道某一时刻只有一个线程在运行。

我们首先来看下异步编程的必要性。下图给出了一些常见的计算机操作耗时对比：

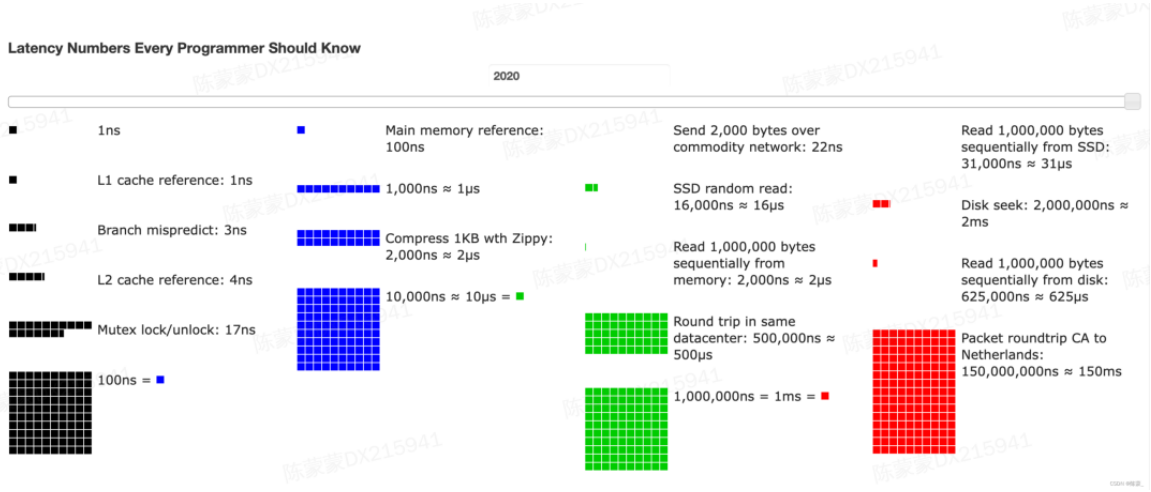

我们近似的认为执行一条计算机指令耗时 1 纳秒，访问内存耗时 100 纳秒，SSD随机读取耗时 16 微妙，一次网络请求耗时在 150 毫秒。

为了个更直观的进行对比，我们抽象出时间颗粒的概念。假设 1 个时间颗粒等于微观中的 1 纳秒、宏观世界中的 1 秒。在这种假设前提下有各个操作的耗时：

操作	耗时/时间颗粒	微观	宏观
CPU 执行1条指令	1	1 纳秒	1 秒
访问内存	100	100 纳秒	1 分 40 秒
SSD 随机读取	16_000	16000 纳秒	4 小时 24 分钟
机械磁盘读取	2_000_000	2 毫秒	23.1 天
网络请求	405_000_000	405 毫秒	12.8 年

相对于常见的 IO 操作，包括文件读写、数据库读写和网络请求等，CPU 实在是太快了。让 CPU 等待本身就是对计算资源的严重浪费。这就好比是，一个网络操作对 CPU 说：你在这里不要动，我去买几个橘子。这一去就是 12.8 年。

对于大前端编程场景尤其如此，我们时刻需要考虑如何避免主线程被阻塞，否则会导致App无响应。

异步编程能有效避免主线程被阻塞，所以我们需要异步编程。

常见的异步编程解决方案有多线程、回调、Promise、Rx 和协程。以抖音发布视频为例，我们假设用户点击发布按钮后经历了三个阶段：

- 准备阶段，通过网络请求提交视频/图片、获取签名相关数据，为耗时操作，耗时在 100 毫秒数量级；
- 提交请求，向抖音后台上传视频、标题、话题等用户数据，为耗时操作，耗时在 100 毫秒数量级；
- 处理提交请求的结果，将成功/失败结果告知用户，在主线程中执行；

上述三个步骤之间具有依赖关系，后者必须等前者执行完成才能开始，在不考虑阻塞主线程的情况下，我们使用同步代码（假设是我们发明的 BPBP 语言，下同）。实现如下：

```
function postItem(item: Item) { // 一个 Item 为一条待发版的抖音视频数据模型
   val token = preparePost() // 网络请求，耗时操作
   val post = submitPost(token, item) // 网络请求，耗时操作
   processPost(post)
}

function preparePost(): Token {...}
function submitPost(t: Token, i: Item): Post {...}
function preparePost(p: Post) {...}多线程
```

多线程

假设我们的 BPBP 语言也是支持多线程的，用 thread 关键字构建线程。那么我们可以用单独的线程执行耗时操作：

```
function postItem(item: Item) {
   thread {
      val token = preparePost()
      val post = submitPost(token, item)
      processPost(post)
   }
}

function preparePost(): Token {...}
function submitPost(t: Token, i: Item): Post {...}
function preparePost(p: Post) {...}
```

同时我们也应该意识到多线程的方式存在诸多缺点：

- 创建开销较大，线程调度时需要上下文切换；
- 数量受限，能启动的最大线程数受操作系统限制，这个限制对于后端应用的影响尤为明显；
- 平台受限，某些平台比如 JavaScript 不支持自定义线程，注意 WebWorker 是浏览器提供的 API 而非 JavaScript 的能力；
- 数据同步带来额外性能开销；
- 对象生命周期不一致造成的内存泄漏；
- 使用难度大，调试多线程、线程安全让人头大；

一提到多线程编程，往往会想到那令人匪夷所思的执行结果，就像下面的2张图一样。

你期待的效果

实际的效果

回调

如果我们用回调的方式解决该问题：

```
function postItem(item: Item) {
   preparePostAsync { token ->
      submitPostAsync(token, item) { post ->
         processPost(post)
      }
   }
}
```

回调的方式简单易懂、开销低、适用范围广，几乎适用于任何异步任务，但是也存在缺陷：

- 嵌套地狱，嵌套层数多，不易理解，维护困难；
- 不易处理异常，如果其中一层回调发生异常，异常的传递和处理都比较困难；
- 多个回调收口困难，比如要等多个回调都完成之后统一执行某个动作；

- 对于回调执行的线程容易出错，常见的问题是回调在子线程执行但是却操作了UI更新；
- 对 for/while、 try-catch 等场景不友好；

只要你愿意，你甚至可以写出下面的嵌套代码：

Promise

Promise 背后的思想是当我们触发一个耗时操作时，我们同步的获取一个实例，在后续某个时间点通过这个实例操作耗时操作的结果。即，这是一个耗时操作，我没法立即给你结果，但是我可以给你一个承诺（Promise），承诺你在不久的 Future 把执行结果告知你。

在不同的平台，这个实例有不同的叫法，比如 Promise|JavaScript 、CompletableFuture|Java、Future|Dart、Deferred|Kotlin 等。

因为 Kotlin 是一个跨平台的语言，可以和 Java、Swift 等进行混合编程，甚至可以导出 JavaScript 代码，为了避免引起混乱，最好避开 Promise、Future 这些已有名词，从而定了个 Future 的近义词 Deferred。

这是后起之秀的常见烦恼，纵然你可以站在巨人的肩膀上，规避前辈（Java、JavaScript 等）踩过的坑，但是也要承受这种"无名可用"的尴尬。包括我们常见的 Vue.js，最初尤雨溪打算将其命名为 view.js，但是这个名字被占用了，他就把 view 用谷歌翻译成各种语言，发现

法语的 vue 还没人用，就用了这个名字。其他行业也有类似的烦恼，特斯拉的车型命名，本想凑个 SEXY，但是 Model E 被福特抢注了，只能将字母 E 翻转下成为 3。

```
function postItem(item: Item) {
   preparePostAsync()
      .then { token -> submitPostAsync(token, item) }
      .then { post -> processPost(post) }
}

function preparePostAsync(): Promise<Token> {...}
function submitPostAsync(): Promise<Post> {...}
function processPost(post: Post) {...}
```

Promise 采用了一种调用链式的编程模型，简化了异步操作，避免了回调地狱，但是同样也存在一些问题，比如：

- 不同平台上 API 命名差异，有的为 thenCompose()、thenAccept() 等等；
- 不符合同步编程习惯，对 for/while、异常处理不友好；
- 对每一步的返回值类型有特殊要求，必须是 Promise，而不能是实际的数据类型；
- 错误处理变得复杂，不易将不同阶段产生的错误一路传递下去；
- 不同阶段之间共享数据困难；

响应式编程

Reactive Extension（简称 Rx）编程模型最初由 Erik Meijer 引入 C# ，但是当时并未受到业界重视。

直到 Netflix 将其移植到 Java 平台，并产生了 RxJava，从此一发不可收，各种 RxXX 如 RxJS、RxSwift 等开始涌现。

Rx 的核心思想是将一切都当做是可观测的数据流，实现方式是观察者设计模式+一系列的扩展方法。

跟 Promise 类似，Rx 的写法跟我们平时写的同步代码也存在差异，这其实也是一种新的编程模型。

Rx 由于封装的过于“简洁”，导致其调试困难，数量众多的扩展函数让人眼花缭乱，存在较抖的学习曲线，容易出错、不易维护。

同时，Rx 在各个平台上的 API 基本具有一致性，而且处理错误的方式也更加友好。

假如我们有 RxBPBP，那么用 RxBPBP 实现笔记发布流程的代码大概是：

```
function postItem(final item: Item) {
   Observable
   .create { subscriber -> {
        Token t = preparePost(); // 获取签名
        subscriber.onNext(t);
        subscriber.onCompleted();
        }
   }
   .subscribeOn(Schedulers.io())
   .map { token -> {
          val p: Post = submitPost(token, item); // 发送网络请求
        return p;
      }
   }
   .subscribeOn(Schedulers.io())
   .subscribeOn(Schedulers.main())
   .subscribe{ {
        function onCompleted() {}
        function onError(e) {}
        function onNext(post) { processPost(post) } // 处理结果
     }
   }
}
```

协程及常见实现

最近十几年，互联网、移动互联网、物联网、车联网等产生的网络请求数量激增，但是大部分请求并不是 CPU 计算密集型而是 IO 密集型的，大部分的请求都是 请求到来——少量计算——调用公共服务——读写数据库——返回数据，当处于读写阻塞时，线程处于阻塞状态，内核调度器会将这个线程挂起，执行其他线程，如果之前的阻塞解除了，再切换上下文，执行之前挂起的线程，CPU 大部分时间花在了切换上下文上。而线程是宝贵的计算资源，数量有限，本身占用存储资源，最好是一直跑，别阻塞、别切换上下文。

以下图为例，我们可以构建三个线程 thread_0、thread_1、thread_2 去处理网络请求，每个线程处理一个请求，但是每个线程大部分时间都处于 IO 阻塞状态。我们也可以只创建一个

线程，而用三个协程去处理这三个网络请求，当请求0处理 IO 时将其对应的协程挂起，继续运行请求2，当请求2处理 IO 时再将其挂起去处理请求1，当请求1挂起时切换到已经就绪的请求2、请求0、请求1。通过这种方式来实现十万级甚至百万级的高并发。

协程这一异步编程模型的优势包括：

- 轻量级：（1）协程的创建、销毁、调度发生在用户态，避免了系统内核级线程频繁切换带来的 CPU 资源浪费，提升了 CPU 的利用率和吞吐量；（2）内存占用小，线程的内存占用在 MB 级别，系统内存的制约导致我们无法开启更多线程实现高并发，而在协程编程模式下，可以轻松有十几万协程，这是线程无法比拟的；
- 提升开发效率：（1）借助协程我们可以以近似同步代码的方式完成异步操作，方便代码的阅读和后续维护；（2）通过结构化并发限定控制域，减少内存泄漏

协程的局限性：

- 不符合结构化编程的理念
- 对于单线程语言，无法利用多核优势
- async/await 限制返回值类型
- 对于Goroutine 排查内存类（Goroutine 逃逸、内存泄漏）错误，排查难度大

- 下面我们以 JavaScript、Dart、Kotlin、Swift 和 Go 为例，看下其对协程的实现情况。

JavaScript

ES2015 引入 Promise/a+、生成器 Generators、关键词 yield。生成器可以赋予函数执行暂停/保存上下文/恢复执行状态的功能， 新关键词 yield 使生成器函数暂停。语法如下：

```
function* gen(){
   yield 1;
   yield 2;
   return 3;
}

// 生成器返回值类型
interface Iterator {
   next(): IteratorResult;
}

// yield 表达式返回值类型
interface IteratorResult {
   value: any;   // yield 表达式返回值
   done: boolean; // 是否还有其他 yield，有-false，无-true
}
```

ES2017 引入 async/await 语法糖，二者均为关键字，async 用于修饰异步函数（将 Generator 函数和自动执行器，包装在一个函数里），此函数需要返回一个 Promise 对象。await 修饰表达式，可以等待一个 Promise 对象 resolve，并拿到结果。

Promise 中也利用了回调函数，在 then 和 catch 方法中都传入了一个回调函数，分别在 Promise 被满足和被拒绝时执行，这样就就能让它能够被链接起来完成一系列任务。

JavaScript 的协程成熟体是 async/await，我们用async/await 方式实现上述案例如下：

```
async function postItem(item) {
   const token = await preparePostAsync()
   const post  = await submitPostAsync(token, item)
   processPost(post)
}

function preparePostAsync() {
   return new Promise(resolve => {
      setTimeout(() => {
```

```
        resolve('token');
      }, 2000);
   });
}

function submitPostAsync() {
   return new Promise(resolve => {
      setTimeout(() => {
         resolve('post');
      }, 2000);
   });
}

function processPost() {}
```

原理：async/await 是由 Promise + Generator 实现的语法糖。将 async/await 转成 Promise+Generator：

```
// 转换成 Promise 的形式
function* postItem(item) {
   let token = yield preparePostAsync()
   let post  = yield submitPostAsync(token, item)
   processPost(post)
}

const iterator = postItem({});
iterator.next().value
  .then((val) =>
    iterator.next(val).value)
  .then((data) => {
    processPost(data);
});

// 生成器返回值类型
interface Iterator {
   next(): IteratorResult;
}

// yield 表达式返回值类型
interface IteratorResult {
   value: any;   // yield 表达式返回值
   done: boolean; // 是否还有其他 yield，有-false，无-true
}

runner(postItem);
```

可能你会说：这种把每个yield翻译成一个Promise的方式有点傻，太不通用了，即使要毁灭地球，我也要写个以 planet 作为入参的通用函数，然后把地球作为入参传进去。是的，其实我们可以更一般化的实现这个转换过程（注意下述代码忽略了对异常的处理）：

```
// 更一般的形式
function runner(genFn) {
   let itr = genFn(); // Iterator 类型，genFn() 不会立即执行，直到 .next() 方法被调用

   function run(arg) {
      let result = itr.next(arg); // IteratorResult 类型，调用next()开始执行到下个 yield，返回
      if (result.done) {
         return result.value;
      } else {
         return Promise.resolve(result.value).then(run); // 等待 Promise 结果，将结果作为 arg
      }
   }

   run();
}
```

在 Generator+yield 在 V8 引擎中是怎么实现的呢?

Generator+yield 属于无栈协程，仍然跟普通的函数用的是同一个调用栈，并没有借助额外的栈去保存暂停点的现场信息，yield 关键字的作用类似属于 return，但是利用状态机和闭包完成了保存上下文的目的，yield 执行之后 Generator 函数仍然会被出栈，当 .next() 方法调用时，再将 Generator 方法入栈，根据之前保存的现场数据（包括程序计数器）来从 yield 暂停点开始继续往下执行。

Dart

Dart async/await 的用法几乎跟 JavaScript 一模一样，甚至连单线程模型、消息队列等都一样，只是在语法上 async 的位置有所不同。

Dart 的目标是取代 JavaScript，虽然是单线程语言，但是其使用 Isolate 实现了多线程。

用 Dart 实现该案例：

```
void main() {
  postItem(Item());
}

void postItem(Item item) async {
  var token = await preparePost();        // 请求签名
  var post = await submitPost(token, item); // 发送网络请求
```

```
  processPost(post);                  // 处理结果
}

Future<Token> preparePost() {
  return Future.delayed(Duration(seconds: 3), () => Token()); // 返回 Future
}

Future<Post> submitPost(Token token, Item item) {
  return Future.delayed(Duration(seconds: 5), () => Post());  // 返回 Future
}

void processPost(Post post) {}
```

Kotlin

Kotlin 是一门 JVM 编程语言，跟 Java 一样，经过编译后生成字节码运行于 JVM 上。

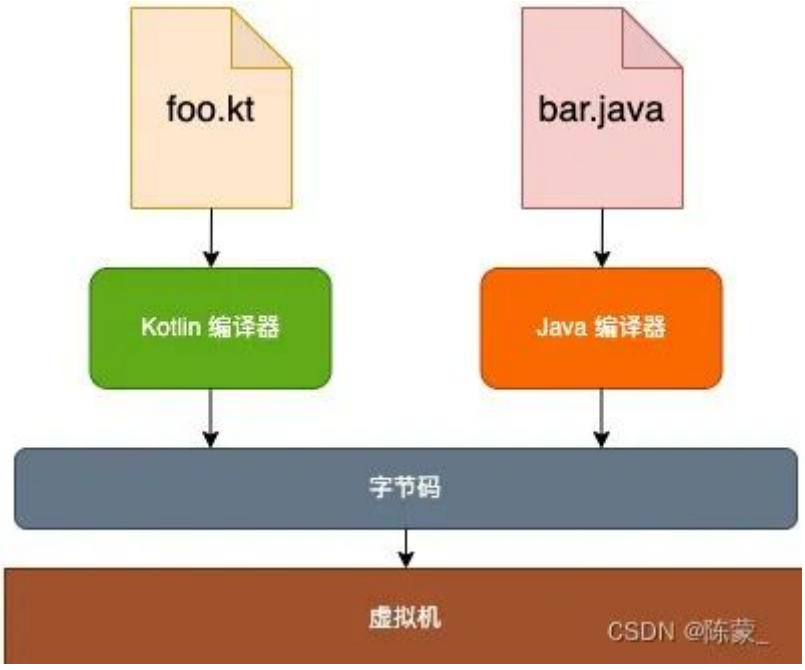

虽然 async/await 方式可以让我们写出近似同步的代码，避免了嵌套地狱，但是也带来了新的问题。最明显的就是 async 修饰的方法的返回值类型受限，必须是 Promise/Future，这种类型代表异步操作。这就导致了我们代码复用受限，比如有些逻辑我们需要在多个地方使用，有的地方返回异步的 Promise/Future，而有的地方可能就是想要用于子线程中，就是想要同步操作。而且 async/await 的方式对异步操作的用法限制过死，限制了开发者发挥的空间，Kotlin 想仅仅制定一个简单而且底层的规则，然后让开发者自有发挥、构建其他的第三方库。

基于这些考虑，Kotlin 并未提供 async/await 关键字，而是仅仅提供了一个 suspend 关键字，用其修饰耗时函数，而且对返回值没有特殊的类型限制。进而通过这个关键字构建出其他的协程操作，比如 async/await 扩展方法。

跟 JavaScript/Dart 不同的是，Kotlin 可以构造线程（线程池），我们可以指定协程在哪类线程中开始执行以及恢复执行。

另外值得注意的是构建 Kotlin 协程的写法，与构建线程的方式非常相似，而且在 suspend 方法内部写的代码就跟同步代码一样：

```
fun main() {
    GlobalScope.launch(Dispatchers.Main) { // 在主线程中触发协程
        postItem(Item())
    }
    Thread.sleep(100)
}

suspend fun postItem(item: Item) {
    val token = preparePost() // 暂停点1：获取签名
    val post = submitPost(token, item) // 暂停点2：发送网络请求
    processPost(post) // 处理结果
}

suspend fun preparePost() : Token = withContext(Dispatchers.IO) { ... }
suspend fun submitPost(t: Token, i: Item) : Post = withContext(Dispatchers.IO) { ... }
fun processPost(post: Post) { ... }
```

使用 Kotlin async/await 方式实现，async() 返回的是一个类似 Promise/Future 的类型——Deferred（为了避免与 Java/JavaScript 混合编程是混淆）：

```
fun postItem(item: Item) {
    GlobalScope.launch {

        // 获取签名
        val deferredToken: Deferred<Token> = async { preparePost() }
        val token: Token = deferredToken.await()

        // 发送网络请求
        val deferredPost: Deferred<Post> = async { submitPost(token, item) }
        val post = deferredPost.await()

        // 处理结果
        processPost(post)
    }
}
```

```
suspend fun preparePost() : Token = withContext(Dispatchers.IO) { ... }
suspend fun submitPost(t: Token, i: Item) : Post = withContext(Dispatchers.IO) { ... }
fun processPost(post: Post) { ... }
```

注意，在耗时方法里面都有 withContext(Dispatchers.IO)，表示这个方法要在 IO 线程中运行。

我们可以借助安卓开发 IDE AndroidStudio 将 Koltin 的协程代码反编译成 Java 代码，从中窥探其实现方法，但是为了避免陷于繁琐的代码细节之中，我们只讲原理。

Kotlin 没有借助 JVM 额外的魔法，是怎么实现协程的暂停和恢复的呢？

既然 Kotlin 有自己的编译器，那可不可以直接将协程代码转成回调嵌套呢？是可以的，但是并未这么做，而是转换成了状态机。

原理：编译器会将上述 suspend 相关代码转换成状态机相关的代码。

首先 suspend 函数会被编译器转成 CPS（Continuation-Passing Style，小名：回调函数）的形式。

比如：

```
suspend fun preparePost() : Token {...}
```

会被转换成：

```
fun preparePost(Continuation<Token> cont) {...}

public interface Continuation<in T> {
   val context: CoroutineContext    // 协程上下文，包括所运行的线程等
   fun resumeWith(result: Result<T>) // 暂停点
}
```

然后为每个暂停点添加一个标记：

```
suspend fun postItem(item: Item) {
```

```
    // state 0
    val token = preparePost() // 暂停点1：获取签名

    // state 1
    val post = submitPost(token, item) // 暂停点2：发送网络请求

    // state 2
    processPost(post) // 处理结果
}
```

再添加状态机：

```
suspend fun postItem(item: Item, cont: Continuation) {
    var stateMachine = cont as? ThisSM ?: object: Continuation { // 可复用状态机
        var state = 0
        override fun resumeWith() {
            postItem(null, this)
        }
    }

    switch(stateMachine.state) {
        case 0:
            stateMachine.state = 1
             stateMachine.item = item
         preparePost(stateMachine) // 暂停点1：获取签名
         return
        case 1:
         stateMachine.state = 2
             val token = stateMachine.result as Token
         val item = stateMachine.item
         submitPost(token, item, stateMachine) // 暂停点2：发送网络请求
         return
        case 2:
             val post = stateMachine.result as Post
         processPost(post, stateMachine) // 处理结果
         return
    }
}

suspend fun preparePost() : Token = withContext(Dispatchers.IO) { ... }
```

其执行过程如下图：

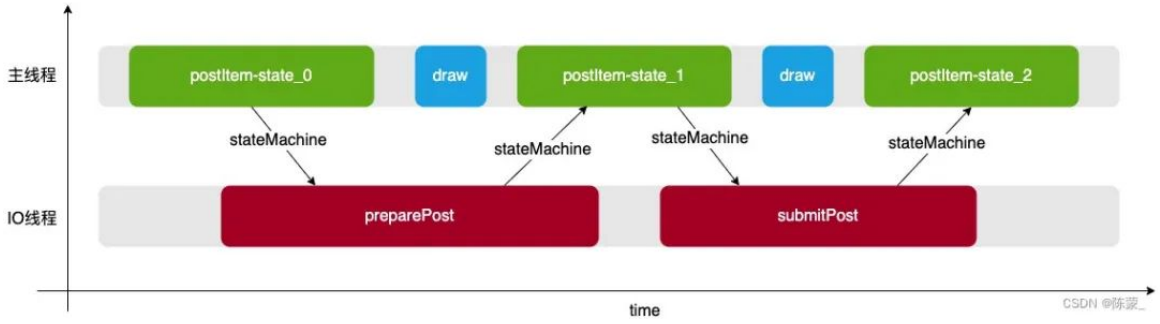

整个执行过程是借助 stateMachine 在主线程中执行了 3 遍 postItem()，每1遍对应1个状态，每1遍执行1个 case 分支，执行完 case 分支立即 return。执行1个 case 分支不代表同步执行完成，也有可能是只是切换到 IO 线程，即触发耗时操作的执行。

在将耗时方法切到IO线程之后，主线程就空闲出来去处理其应该做的事情，比如视图渲染等，从而避免主线程被卡死。

由此可以看出，Kotlin 并未借助栈来实现协程的暂停和恢复，而是通过状态机和闭包来实现的，状态机和闭包作为局部变量是存储在堆上的，占用的内存空间更小。

Kotlin 协程的暂停和恢复同样离不开线程的切换，从某种程度上说，Kotlin 协程本质上是一个线程调度的框架。

一旦启动一个协程，如何取消呢？不取消会产生资源泄漏的问题。JavaScript是通过AbortController，而Kotlin与Swift 类似，是通过结构化并发的方式实现的。

Swift

在 Swift 中我们使用 Task 构建协程实例，一个 Task 就是一个协程，用 Swift 协程实现笔记发布流程：

```
override func viewDidLoad() {
   super.viewDidLoad()
   Task {
      let token = try await preparePost()
      let post  = try await submitPost(token, item)
      processPost(post)
   }
}

func preparePost() async throws -> Token
```

```
func submitPost(_ t: Token, _ i: Item) async throws -> Post

@MainActor
func processPost(_ p : Post) async throws -> Void
```

使用 async/await 不会阻塞主线程，在一个 Task 中使用 await 时后面的任务将会被挂起，等到 await 任务执行完后，会回到被挂起的地方继续执行。Swift 的协程也是一种结构化并发（Structured Concurrency），类似于 Kotlin 中的 Job，Task 之间具有树状父子关系，取消父协程会同步取消其子孙协程。

Go

虽然我们这边文章主要面向大前端读者，但是说到协程这个话题，无论如何绕不开 Go 语言的。但是由于笔者本人才疏学浅（不夸张的说，光一个 GMP 模型估计都能写本书），实在不敢班门弄斧，我们浅尝辄止。

Go 中没有线程概念，只有 Goroutine，可以看做是轻量级的线程，Goroutine 是实现高并发的关键。

- Goroutine 有栈协程，每个协程有独立的栈，而栈既保留了变量的值，也保留了方法的调用关系、参数和返回值。
- Go 采用 GMP 模型实现高并发，GMP分别代表：
- G - Goroutine，Go协程，是参与调度与执行的最小单位
- M - Machine，指的是系统级线程
- P - Processor，指的是逻辑处理器，P关联了的本地可运行G的队列(也称为LRQ)，最多可存放256个G

GMP调度流程大致如下：

- 线程M想运行任务就需得获取 P，即与P关联
- 然从 P 的本地队列(LRQ)获取 G
- 若LRQ中没有可运行的G，M 会尝试从全局队列(GRQ)拿一批G放到P的本地队列，
- 若全局队列也未找到可运行的G时候，M会随机从其他 P 的本地队列偷一半放到自己 P 的本地队列
- 拿到可运行的G之后，M 运行 G，G 执行之后，M 会从 P 获取下一个 G，不断重复下去

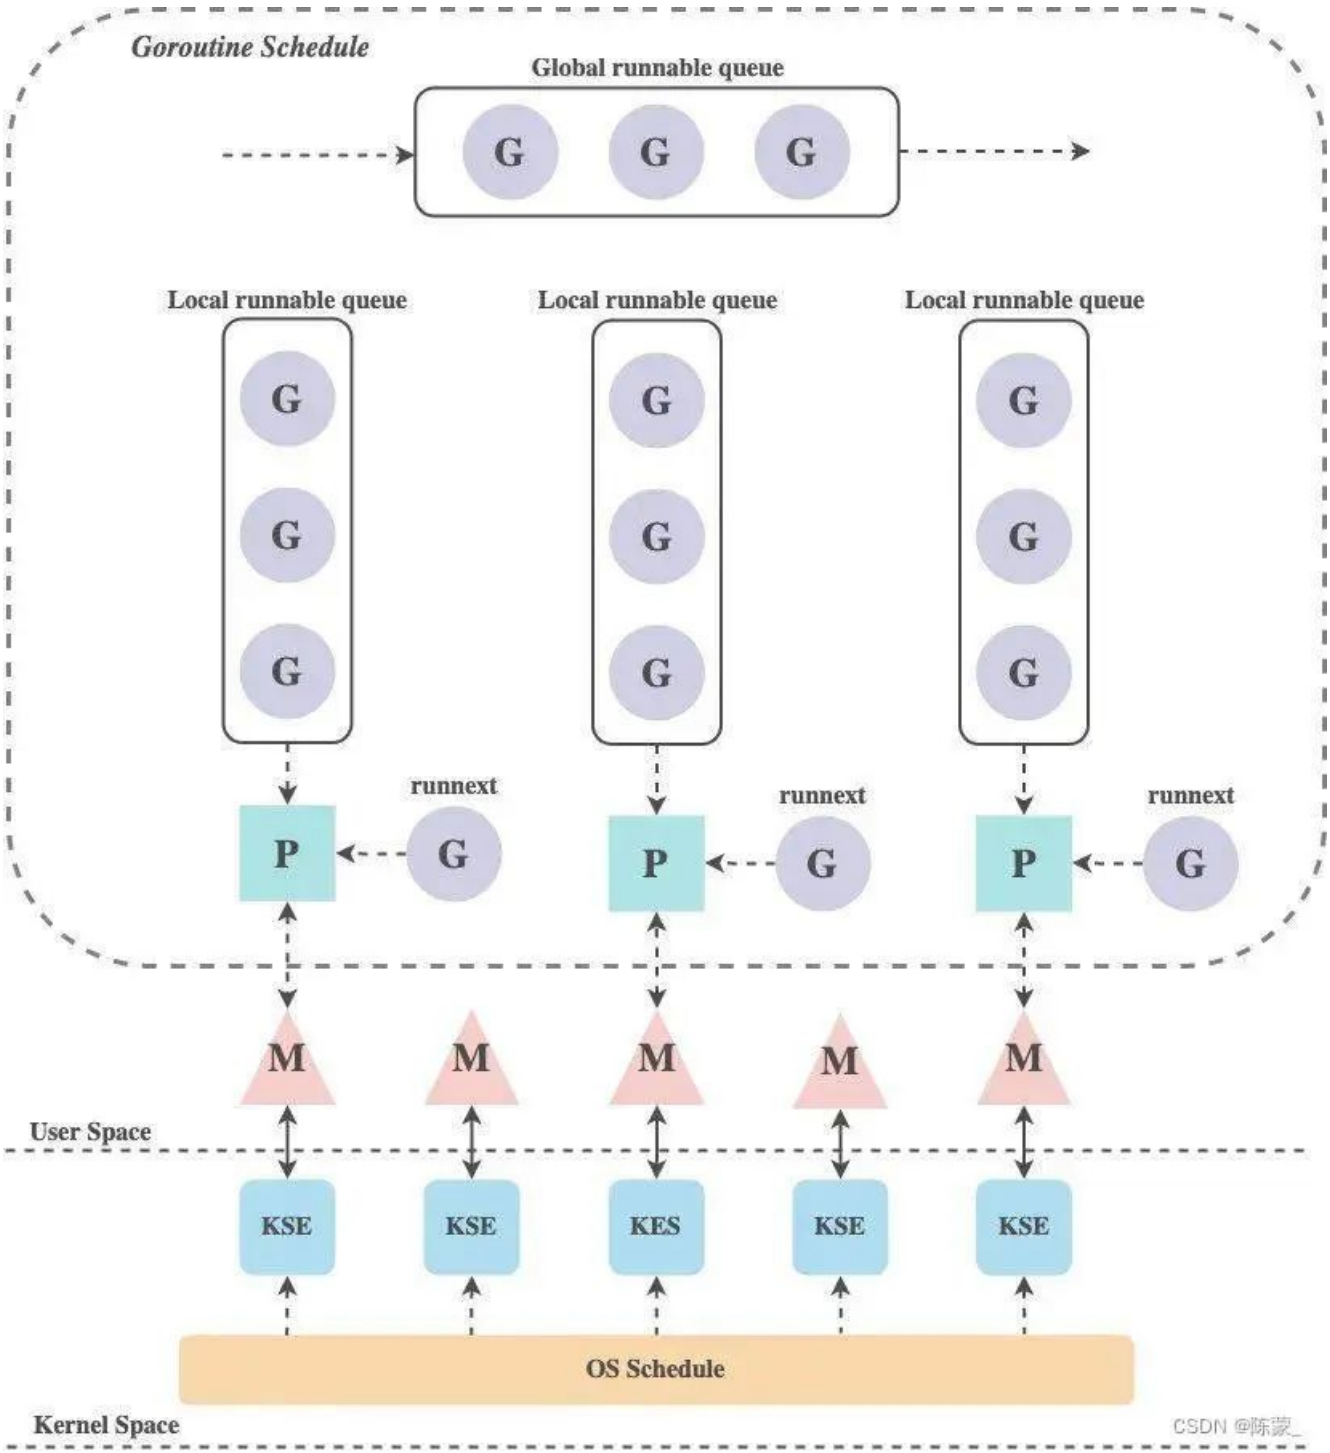

在Go语言中，我们不需要使用 async/await、suspend 关键字，也不需要对耗时函数返回结果进行特别修饰、做特殊包装，只需一个 go 关键字即可。

可以说 Go 语言是协程的终极形态，用 Go 写异步操作就跟同步代码没有什么区别，在开发体验上达到了完美的程度。

我们用 Go 代码实现笔记发布流程（可用在线编译环境复现）：

```
package main
```

```
import (
   "fmt"
   "sync"
)

var waitGroup = sync.WaitGroup{}

func main() {
   waitGroup.Add(1)
   go postItem(Item{})
   waitGroup.Wait()
}

func postItem(item Item) {
   fmt.Println("Hello, 世界")

   var token = preparePost()
   var post = submitPost(token, item)
   processPost(post)

   waitGroup.Done()
}

func preparePost() Token {
   fmt.Println("preparePost")
   return Token{}
}

func submitPost(token Token, item Item) Post {
   fmt.Println("submitPost")
   return Post{}
}

func processPost(post Post) {
   fmt.Println("processPost")
}

type Token struct{}
type Post struct{}
type Item struct{}
```

推荐阅读：

我的新书，《第一行代码 第3版》已出版！

Android 13运行时权限变更一览

PermissionX 1.7发布，全面支持Android 13运行时权限

欢迎关注我的公众号

学习技术或投稿

▼

长按上图，识别图中二维码即可关注

阅读原文

喜欢此内容的人还喜欢

最适合孩子入门的十大编程语言

CSDN

为什么C++中有函数指针还需要std::function?

码农的荒岛求生

总结 mysql 的所有 buffer，一网打尽就这篇了！

yes的练级攻略